

למידת מכונה – פרויקט סיום:

זיהוי אנשים

תמר בר-אילן: 323861021

אופק כץ: 315138693

קישור לגיט

תיאור המאגר: המאגר שלנו מכיל תמונות של מצלמות אבטחה בחלקן מופיעים אנשים ובחלקן לא. המאגר מתויג בצורה הבאה: 0 לתמונה ללא אנשים, ו-1 לתמונה עם אנשים.

קישור למאגר – נלקח מ-kaggle

בחרנו מאגר זה בגלל התפקיד המרכזי שהוא ממלא בקידום כלי רכב אוטונומיים ושילובם במערכות התחבורה העתידיות שלנו. זיהוי אנשים הוא מרכיב קריטי בהגברת הבטיחות הנהגים והן להולכי הרגל.

השאלה המרכזית בה נתעמק: האם גודל התמונה משפיע על אחוז הטעות של כלי הלמידה השונים שבחרנו?

במאגר הנבחר התמונות לא בגודל אחיד, לכן תחילה קבענו גודל קבוע- X128128 ושינינו את כל התמונות לגודל זה. בנוסף לצורך השוואה החלטנו להקטין את גודל התמונות 64X64 ולראות כיצד זה משפיע על אחוז הטעות.

השתמשנו בכלי למידה הבאים:


1. Adaboost
2. Svm
3. Knn
4. neural networks

העברת התמונות לווקטורים:

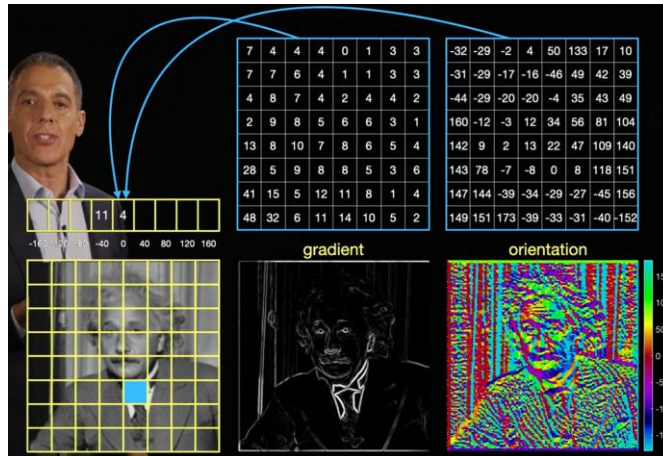
בחרנו ב-2 שיטות שונות למעבר בין תמונה לווקטור והרצנו את כלי הלמידה – AdaBoost לבדיקה איזה שיטה טובה יותר.

השיטות שבחרנו:


1. flatten- שיטה שמעבירה מתמונה לווקטור ע"י שורה אחר שורה.



2. HOG – (Histogram of Oriented Gradients) שיטה שמחלצת מידע על כיווני השיפוע הקיימים בתמונה. בדר"כ מוציאה תמונה- אנחנו עצרנו שלב אחד לפני- בהינתן וקטור.



תוצאות AdaBoost:



שיטה 1: Flattening

- דיוק האימון: 95.11%

- דיוק הבדיקה: 54.89%

שיטת זו השיגה דיוק גבוה יחסית באימון (95.11%), מה שמצביע על כך שמסווג AdaBoost שאומן על וקטורים של תמונה שטוחה יכול ללמוד ביעילות את הדפוסים בנתוני האימון. עם זאת, דיוק הבדיקה (54.89%) נמוך במידה ניכרת מדיוק האימון, מה שמרמז על התאמת יתר.

שיטה 2: HOG (Histogram of Oriented Gradients)

- דיוק האימון: 94.29%

- דיוק הבדיקה: 63.04%

שיטת HOG השיגה דיוק אימון מעט נמוך יותר בהשוואה לשיטת Flattening (94.29% לעומת 95.11%). עם זאת, דיוק הבדיקה (63.04%) גבוה באופן ניכר מזה של שיטת Flattening. זה מצביע על כך שתכונות ה-HOG לכדו מידע מבחין יותר על התמונות, מה שהוביל לביצועי הכללה טובים יותר על העולם.


השוואה בין 2 השיטות:

- שיטת HOG עלתה על שיטת Flattening מבחינת דיוק הבדיקה (63.04% לעומת 54.89%).
- בעוד ששיטת Flattening השיגה דיוק אימון גבוה יותר, היא סבלה מביצועי הכללה גרועים יותר בעולם, דבר המצביע על התאמת יתר פוטנציאלית.
- שיטת HOG, למרות דיוק האימון מעט נמוך יותר, הדגימה הכללה טובה יותר על העולם, מה שמצביע על כך שתכונות ה-HOG שלפנו מידע רלוונטי יותר עבור משימת הסיווג.

:AdaBoost

כעת נריץ את כלי הלמידה adaboost שוב אך הפעם לשם השוואה על גודל התמונות. פעם אחת על תמונות בגודל 128X128 ופעם שנייה על תמונות בגודל 64X64, כאשר העברנו בין תמונות לווקטורים עם HOG.

תוצאות:



עבור תמונות בגודל 128X128:

- דיוק האימון: 96.74%

- דיוק בדיקה: 61.96%

עבור תמונות בגודל 64X64:

- דיוק אימון: 93.89%

- דיוק בדיקה: 68.48%

השוואה:

השוואת דיוק אימון:

- למסווג AdaBoost שאומן על תמונות בגודל 64×64 יש דיוק אימון מעט נמוך יותר בהשוואה למסווג שאומן על תמונות בגודל 128×128 . זה מצביע על כך שהמסווג שאומן על תמונות גדולות יותר עשוי להתאים טוב יותר לנתוני האימון.

השוואת דיוק בדיקה:


- למסווג AdaBoost שאומן על תמונות בגודל 64×64 יש דיוק בדיקה גבוה יותר בהשוואה למסווג שאומן על תמונות בגודל 128×128 . זה מצביע על כך שהמסווג שאומן על תמונות קטנות יותר מביא תוצאות טובות יותר על העולם, ואילו בתמונות בגודל 128×128 יש כנראה התאמת יתר.

לפי התוצאות ניתן להסיק כי AdaBoost עובד טוב יותר על נתונים פחות מורכבים וככל שמעלים את רזולוציית התמונה, אחוז הטעות על העולם גדל ויש התאמת יתר.

:SVM

הרצנו את כלי למידה זה פעמיים- פעם אחת על תמונות בגודל 128×128 ופעם שנייה על תמונות בגודל 64×64 , כאשר העברנו בין תמונות לווקטורים עם HOG.

תוצאות:



ננתח את התוצאות:

SVM עם תמונות בגודל 128X128:

- דיוק אימון: 96.60%

- דיוק בדיקה: 69.02%

SVM עם תמונות בגודל 64X64:

- דיוק אימון: 94.29%

- דיוק בדיקה: 70.11%

השוואה:

דיוק האימון:

- מסווג SVM עם תמונות בגודל 64X64 השיג דיוק אימון מעט נמוך יותר (94.29%) בהשוואה לזה שאומן עם תמונות בגודל 128X128 (96.60%). זה מצביע על כך שגודל התמונה הגדול יותר מאפשר לדגם ללכוד פרטים נוספים מנתוני האימון, מה שמוביל לביצועים טובים יותר בערכת האימונים.

דיוק בדיקה:


- מסווג ה-SVM שאומן עם תמונות בגודל 64X64 (70.11%) עלה על זה שאומן עם תמונות בגודל 128X128 (69.02%) במערך הבדיקות. זה מצביע על כך שגודל התמונה הקטן יותר עשוי להכליל טוב יותר על העולם, אולי בגלל המורכבות המופחתת או התאמת יתר.

לפי התוצאות ניתן להסיק כי SVM עובד טוב יותר על נתונים פחות מורכבים וככל שמעלים את רזולוציית התמונה, אחוז הטעות על העולם גדל ויש התאמת יתר – נציין שהשינוי בגודל התמונה משפיע באופן מינימלי.

:Knn

הרצנו את כלי למידה זה פעמיים- פעם אחת על תמונות בגודל 128X128 ופעם שנייה על תמונות בגודל 64X64, כאשר העברנו בין תמונות לווקטורים עם HOG.

תוצאות:



ניתוח עבור 128X128:

- דיוק האימון: 69.16%

- דיוק בדיקה: 61.41%

ניתוח עבור 64X64:

- דיוק האימון: 71.60%

- דיוק בדיקה: 63.04%

השוואה:

- דיוק אימון: ה-KNN השיג דיוק אימון מעט גבוה יותר כאשר התאמן על תמונות בגודל 64X64 בהשוואה לתמונות בגודל 128X128.

- דיוק בדיקה: באופן דומה, דיוק הבדיקה היה מעט גבוה יותר גם עבור תמונות בגודל 64X64 בהשוואה לתמונות בגודל 128X128.

- הדיוק הגבוה יותר שהושג עם תמונות בגודל 64X64 יכול להצביע על כך שהתמונות ברזולוציה הנמוכה יותר מכילות מספיק מידע כדי שהמסווג של KNN יפעל היטב.

- ייתכן שהתמונות ברזולוציה נמוכה יותר מובילות להפחתה במורכבות החישובית, מה שהופך את תהליך הסיווג ליעיל יותר מבלי לוותר על הדיוק.

- עם זאת, חשוב לציין שההבדלים בדיוק בין שני הגדלים שוליים יחסית.

:neural networks


בחרנו ברשת נוירונים CNN – Convolutional Neural Network (רשת קונבולוציה)

יש לנו סה"כ 920 תמונות (עם ובלי אנשים), הגדרנו- epoch 30, batch 20

(30 חזרות על כל התמונות, כאשר כל חזרה מחולקת לחבילות של 20 תמונות- סה"כ 46 סבבים בכל חזרה (920\20))

עבור כל epoch חישבנו דיוק- אחוז התמונות בהן המודל צדק בתיוג, והפסד- מדד לביצועי המודל במהלך האימון, כאשר ערכים נמוכים יותר מעידים על ביצועים טובים יותר.

תוצאות על תמונות בגודל 128X128:

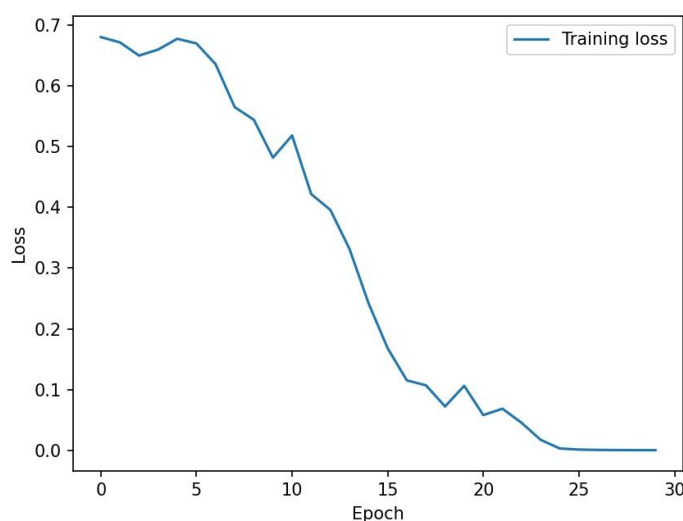


- epoch 1-6: הדיוק גדל בהתמדה בין 58% ל-77%. ההפסד יורד באופן משמעותי מסביבות 0.70 ל-0.51. זה מצביע על כך שהמודל לומד להבחין בין תמונות עם ובלי אנשים, כפי שמעידים על שיפור הדיוק והירידה בהפסד.

- epoch 7-11: הדיוק ממשיך לעלות, ומגיע בסביבות 95%, בעוד ההפסד פוחת עוד יותר. זה מצביע על כך שהמודל לומד דפוסים מורכבים יותר בנתונים.

- epoch 12-30: הדיוק נשאר גבוה, מגיע ל-100% לאחר epoch 23. ההפסד פוחת בהדרגה, מה שמצביע על כך שהמודל מתכנס לפתרון. עם זאת, ההפסד עדיין יורד, אם כי בקצב איטי יותר, מה שמרמז על כך שיתכן שיש התאמת יתר בזמן שהמודל ממשיך ללמוד מנתוני האימונים.

גודל תמונה 64X64:



- epoch 1-4: הדיוק נע בין 57% ל-63%, וגם ההפסד משתנה. אין מגמה ברורה של שיפור ברמת הדיוק או הפחתה בהפסד.

- epoch 5-10: הדיוק משתפר מעט ומגיע לסביבות 76%, אך הוא נשאר נמוך יחסית לדגם שאומן על תמונות X128128. ההפסד פוחת, מה שמעיד על למידה מסוימת, אך הוא נשאר גבוה יחסית למודל האחר.

- epoch 11-30: הדיוק ממשיך לעלות, ומגיע ל-100% לאחר epoch 25. ההפסד יורד באופן משמעותי, מה שמצביע על כך שהמודל מתכנס לפתרון. עם זאת, עקומות הדיוק והאובדן לא יציבות יותר בהשוואה לדגם שאומן על תמונות בגודל X128128, מה שמצביע על כך שהאימון עשוי להיות פחות יציב עם תמונות קטנות יותר.

השוואה בין גדלי התמונות:

- דיוק: הדגם שאומן על תמונות בגודל X128128 משיג דיוק גבוה יותר לאורך האימון בהשוואה לדגם שאומן על תמונות 64X64. הדיוק של הראשון מגיע ל-100% מהר יותר ונראה כי הוא יציב יותר, מה שמעיד על כך שהוא לומד ייצוגים טובים יותר מתמונות ברזולוציה גבוהה יותר.

- הפסד: הדגם שאומן על תמונות X128128 משיג הפסד נמוך יותר במהלך האימון בהשוואה לדגם שאומן על תמונות 64X64. זה מצביע על כך שהמודל הקודם לומד בצורה יעילה יותר ומתכנס לפתרון טוב יותר.

לסיכום, הדגם שאומן בתמונות בגודל X128128 עולה על הדגם שאומן בתמונות בגודל 64X64 מבחינת דיוק והפסד. זה מצביע על כך **ששימוש בתמונות ברזולוציה גבוהה יותר יכול להוביל לביצועים טובים יותר במשימה זו של זיהוי אנשי**. עם זאת, חשוב לציין ששימוש בתמונות ברזולוציה גבוהה יותר עשוי לדרוש משאבי חישוב רבים יותר וזמן אימון גבוה יותר.

השוואת כלל כלי הלמידה:

בתחילת המחקר הנחנו שככל שהתמונה תהיה גדולה יותר וברזולוציה טובה יותר, יהיה לכלי הלמידה יותר נתונים לעבוד איתם ולכן גם אחוז טעות נמוך יותר.

התחלנו להריץ את הכלים השונים על שני גדלי התמונות (64X64, 128X128) והופתענו לגלות כי ב-3 מתוך 4 כלים היה דפוס שחזר על עצמו בו בעולם אחוז הטעות על התמונות הקטנות היה נמוך יותר ולכן טוב יותר.

כיוון שזה חזר ב-3 כלי למידה שונים ניסינו להבין את מקור תופעה זו, חשבנו שהסיבה לכך היא שכלי למידה אלה לא נועדו לסווג נתונים מסובכים מידי ועובדים טוב יותר עם נתונים פשוטים ולכן קיבלנו תוצאות טובות יותר על תמונות עם רזולוציה נמוכה.

חשוב לציין כי אמנם אחוז הדיוק על תמונות ברזולוציה נמוכה היה טוב יותר אך באופן מינימלי ולא משמעותי מידי.

בנוסף דפוס שחזר על עצמו, אחוז הדיוק על המדגם היה גדול משמעותית מאחוז הדיוק על העולם, שכנראה נובע מהתאמת יתר.

לעומת זאת, בכלי הלמידה - neural networks התוצאות התאימו לציפיות שלנו- גודל התמונה הגדול יותר- עם הרזולוציה הגבוהה יותר היה באחוז דיוק גבוה יותר גם על המדגם וגם על העולם.

קשיים שנתקלנו בהם:

מכיוון שציפינו לתוצאות שונות, חשבנו שישנה טעות במדגם או בקוד שלנו על כלי הלמידה השונים, אך בסוף הבנו שאלו כלים שמתמודדים עם נתונים פשוטים יותר טוב יותר.

בנוסף, כלי הלמידה של רשתות נוירונים לא נלמד בכיתה והיינו צריכות להשלים את החומר בעצמנו.

תודה על ההזדמנות ללמוד ולחקור, נהנינו מאוד.

תמר בר-אילן: 323861021

אופק כץ: 315138693